TRABALHO FINAL DE POO
Aprendizado de Máquina com Banco de Dados
KNN e K-Means sobre o perfil de pessoas jogadoras - Programação Orientada a Objetos (Java) e Banco de Dados

1. Contexto

Uma plataforma de jogos online guarda, em um banco de dados, o comportamento de suas pessoas jogadoras. Vocês vão implementar dois algoritmos sobre esses dados, lidos do banco:

- **KNN (classificação):** dada uma pessoa jogadora nova, qual é o seu perfil: casual, regular ou ranqueado?
- **K-Means (agrupamento):** sem olhar para o perfil, as pessoas jogadoras formam grupos naturais?

O trabalho é o mesmo para as duas disciplinas (Programação Orientada a Objetos, em Java; e Banco de Dados). A seção 9 traz o que é específico de POO; a nota de Banco de Dados segue os critérios da professora dessa disciplina.

2. Os dados

São **150 pessoas jogadoras** (dados sintéticos), 50 de cada perfil, na tabela **jogador**. Arquivos fornecidos: **jogadores.sql** (cria a tabela e insere os registros; SQL padrão) e **jogadores.csv** (os mesmos dados).

Coluna	Tipo	Descrição
id	INT (chave)	Identificador.
apelido	VARCHAR(40)	Nome de jogo (gamer tag).
horas_semana	DOUBLE	Horas jogadas por semana.
partidas_semana	INT	Partidas disputadas por semana.
gasto_mensal	DOUBLE	Gasto mensal dentro do jogo, em reais.
taxa_vitoria	DOUBLE	Partidas vencidas, em % (0 a 100).
perfil	VARCHAR(20)	CASUAL, REGULAR ou RANQUEADO: o rótulo que o KNN prevê.

As características têm escalas muito diferentes (o gasto vai a centenas; as horas, a dezenas). Isso afeta a distância e é o tema da normalização.

3. Conceitos de apoio

- **Normalização min-max:** x' = (x − mínimo) / (máximo − mínimo), levando cada característica a [0, 1]. Mínimo e máximo vêm só do treino.
- **Inércia (K-Means):** soma das distâncias ao quadrado de cada ponto ao centroide do seu grupo; quanto menor, mais compactos os grupos.
- **Pureza (K-Means):** soma, por grupo, da contagem do perfil mais frequente, dividida pelo total. Vale 1,0 quando cada grupo tem um único perfil.

4. Parte A - Banco de dados

1. Carreguem o **jogadores.sql** e confiram que a tabela tem 150 linhas.
2. Escrevam três consultas SQL e incluam cada uma, com o resultado, no relatório: (a) quantas pessoas jogadoras há em cada perfil; (b) a média de cada característica por perfil (GROUP BY); (c) apelido e perfil de quem tem mais de 20 horas semanais e taxa de vitória acima de 55%, ordenados da maior para a menor taxa.
3. Os algoritmos devem receber os dados lidos do banco, não valores digitados no código.

5. Parte B - KNN

1. Embaralhem com semente fixa e separem 80% para treino e 20% para teste. Normalizem com min-max, ajustando o normalizador somente com o treino.
2. Implementem o KNN com distância euclidiana, votação entre os K vizinhos e uma regra de desempate que vocês definem e documentam.
3. Apresentem a acurácia no teste para K = 1, 3, 5, 7, 9 e 11.
4. Com um K escolhido, comparem a acurácia com e sem normalização e com distância euclidiana e de Manhattan.
5. Apresentem a matriz de confusão do K escolhido e classifiquem uma pessoa jogadora nova, que não está no banco.

6. Parte C - K-Means

1. Normalizem todas as pessoas jogadoras (não há divisão treino/teste: o K-Means não usa os perfis).
2. Implementem o K-Means: centroides iniciais sorteados entre os dados, repetição até nenhum ponto trocar de grupo ou até um limite de iterações, e tratamento de grupo vazio.
3. Método do cotovelo: inércia para K = 1 a 6, em um gráfico.
4. Com K = 3, apresentem o tamanho dos grupos, os centroides na escala original, a tabela de grupos por perfil real e a pureza. Repitam sem normalizar e comparem.

O resultado depende dos centroides iniciais: rodem várias vezes com sementes diferentes e fiquem com a menor inércia.

7. Parte D - Relatório

Um relatório em **Google Docs, de 4 a 7 páginas**, com as consultas e resultados da Parte A, as tabelas, a matriz e o gráfico das Partes B e C e a pergunta da Parte E (cada grupo recebe uma pergunta diferente).

8. Parte E - A pergunta do seu grupo

Cada grupo recebe uma pergunta de pesquisa diferente para responder com os mesmos dados e algoritmos. A resposta entra no relatório em uma seção "Parte E" de 1 a 2 páginas, com tabela ou gráfico e um texto apoiado nos números. Como a acurácia em 30 pessoas de teste varia muito entre divisões, quando o experimento pedir repetição usem pelo menos 20 divisões e informem média e desvio padrão. As perguntas estão na última página deste PDF.

9. Requisitos da versão Java (POO)

Há um código-base com a conexão, o DAO e a leitura dos dados prontos; as classes marcadas com TODO são de vocês.

- **Enum e imutabilidade:** Perfil é um enum e Jogador é imutável.
- **DAO:** acesso aos dados por uma interface JogadorDAO e uma implementação JDBC com PreparedStatement.
- **Distância como interface:** o KNN depende de MedidaDeDistancia (euclidiana e Manhattan); trocar a distância não pode exigir mudar o KNN.
- **Sem bibliotecas de ML:** só o JDK e o driver do banco.

10. Avaliação (POO) e entrega

Critério	**Pontos**
Banco de dados e DAO (Parte A)	2
Divisão treino/teste e normalização	2
KNN: implementação e experimentos (Parte B)	2
K-Means: implementação e experimentos (Parte C)	2
Projeto orientado a objetos e documentação	3
Pergunta do grupo (Parte E)	3
Total	14

Entrega: **um .zip** com os arquivos .java e o relatório em Google Docs, com os nomes de todas as pessoas do grupo. A data da entrega será na trimestral.